

Analiza właściwości diamentów

Dawid Stasiak s223311
Artur Nejmanowski s223480
Wojciech Seńko s223467
Hubert Murawski s223341
Jakub Rosa s223553

15 kwietnia 2025

1. Wprowadzenie
 - 1.1. Streszczenie
 - 1.2. Słowa Kluczowe
2. Przedmiot analizy
 - 2.1. Cel analizy
 - 2.2. Przegląd literatury
 - 2.3. Opis cech
 - 2.4. Obróbka danych
 - 2.4.1. Braki w danych
 - 2.4.2. Mapowanie zmiennych dyskretnych
3. Opis metod
 - 3.1. K-Means
 - 3.2. Metoda Warda
 - 3.3. Metoda łokcia
 - 3.4. Metoda Silhouette Score
 - 3.5. Wybór ilości klastrow
4. Rezultaty
 - 4.1. Wykresy K-Means
 - 4.2. Wykresy Warda

5. Klasyfikacja
6. Podsumowanie
 - 6.1. Wnioski z analizy danych
 - 6.2. Ocena metod klasteryzacji
 - 6.3. Znaczenie wyników
 - 6.4. Rekomendacje i możliwości dalszych badań
 - 6.5. Realizacja celu
 - 6.6. Porównanie z wynikiem z literatury
7. Bibliografia

1. Wprowadzenie

2. Streszczenie

Projekt dotyczy analizy właściwości diamentów w kontekście ich cen. Wykorzystując techniki eksploracji danych i klasteryzacji, przeprowadzono badanie mające na celu lepsze zrozumienie zależności między cechami fizycznymi diamentów a ich wartością rynkową.

3. Słowa Kluczowe

- ***K-means*** - to często wykorzystywana metoda klasteryzacji, która dzieli dane na k grup (klastry) w taki sposób, aby obiekty w obrębie jednej grupy były do siebie jak najbardziej podobne.
- ***Metoda Warda*** - to technika hierarchicznej analizy skupień, która minimalizuje sumę kwadratów odchyień obserwacji od środka klastra. Jest często stosowana, gdy zależy nam na uzyskaniu skupień o zbliżonej liczności i zwartej strukturze.
- ***Metoda łokcia*** - to technika służąca do określenia optymalnej liczby klastrów w analizie skupień, np. w algorytmie k-średnich.
- ***Centroid*** – środek klastra, obliczany jako średnia wartości wszystkich punktów należących do danego klastra. W algorytmie K-means decyduje o przypisaniu punktów do grupy, ponieważ każdy punkt przypisywany jest do najbliższego centroidu.

- **Odległość euklidesowa** – jedna z najczęściej wykorzystywanych metryk odległości w analizie danych. Obliczana jako pierwiastek z sumy kwadratów różnic między odpowiadającymi sobie współrzędnymi dwóch punktów. Wykorzystywana m.in. w metodzie K-means i Warda.

4. Przedmiot analizy

5. Cel analizy

Celem analizy jest ocena, czy ceny diamentów są adekwatne do ich rzeczywistych właściwości oraz identyfikacja tych cech, które szczególnie wpływają na cenę. Klasteryzacja umożliwia pogrupowanie diamentów o podobnych parametrach i porównanie powstałych klastrów z grupami cenowymi opartymi o rzeczywiste ceny diamentów obecnych w klastrze, co pozwala wykryć potencjalne nieprawidłowości w wycenie i lepiej zrozumieć znaczenie takich cech jak karat, czystość, barwa czy jakość szlifu.

6. Przegląd literatury

- Serwis 301 Carats (9) badał zależności pomiędzy ceną diamentów, a ich właściwościami. Wśród badanych właściwości znalazły się: Karat, czyli masa diamentu, kształt, szlif, czystość, czy kolor. Serwis podaje o ile średnio procent różnią się ceny diamentów o różnych wartościach każdej z tych cech. Z informacji wynika, że wszystkie te cechy mają wpływ na cenę diamentów.


7. Opis cech

W wykorzystanej bazie danych - składającej się z 53940 rekordów - diamenty opisane są przez 10 cech.

- Cena (price) – cena w dolarach amerykańskich. Główna badana cecha. (\$326–\$18,823).
- Karat (carat) – masa diamentu w karatach. (0.2–5.01)
- Szlif (cut) – jakość szlifu. (Fair, Good, Very Good, Premium, Ideal)
- Kolor (color) – kolor diamentu. od J (najgorszy) do D (najlepszy)
- Czystość (clarity) – przejrzystość diamentu. (I1 (najgorsza), SI2, SI1, VS2, VS1, VVS2, VVS1, IF (najlepsza))
- x – długość w mm (3.73–10.74)
- y – szerokość w mm (3.68–58.9)
- z – głębokość w mm (1.07–31.8)
- Głębokość (depth) = $\frac{z}{\text{średnia}(x,y)} = \frac{2 \cdot z}{x+y}$

(43%–79%)

- Tafla (table) – szerokość górnej części diamentu względem najszerszego punktu. (43%–95%)












Rysunek 1: Wymiary diamentu.

Podsumowanie statystyczne (min, max, średnia, mediana, odchylenie standardowe, skośność)


	min	max	mean	median	std	skew
carat	0.2	5.01	0.79769826	0.7	0.47379529	1.11620748
depth	43.0	79.0	61.74951409	61.8	1.43233107	-0.0817265
table	43.0	95.0	57.4568342	57.0	2.23406421	0.79679949
price	326.0	18823.0	3930.99323071	2401.0	3987.28044598	1.61834863
x	3.73	10.74	5.73162685	5.7	1.11942283	0.3983475
y	3.68	58.9	5.73488705	5.71	1.1401258	2.46221061
z	1.07	31.8	3.54004636	3.53	0.70253034	1.58548977

Tabela 1: Podsumowanie statystyczne dla zmiennych ciągłych





Rysunek 2: Wykresy pudełkowe oraz histogramy dla zmiennych ciągłych



Rysunek 3: Wykresy kołowe dla zmiennych jakościowych

8. Obróbka danych

9. Braki w danych

Z bazy danych usunięto 20 wierszy, w których którakolwiek wartość z wymiarów diamentu była zerowa, co stanowiło to niecałe 0.037% całego zbioru. W reszcie danych nie stwierdzono innych braków ani błędnych wartości.

10. Mapowanie zmiennych dyskretnych

W ramach analizy diamentów przeprowadzono konwersje zmiennych dyskretnych na zmienne całkowite. Transformacja była niezbędna do zastosowania algorytmów klasteryzacji K-Means oraz metody Warda. Wartości każdej zmiennej dyskretnej można uszeregować od najgorszej do najlepszej, dlatego w celu łatwiejszej interpretacji wykresów najmniejsza wartość ("1") zawsze oznacza wartość najlepszą, a największa najgorszą.

11. Opis metod

12. K-Means

Metoda k-means polega na podziale zbioru danych na k klastrow, przy czym liczba k jest ustalana z góry. Działa iteracyjnie: algorytm losowo wybiera k punktów jako początkowe centroidy (środki klastrow), następnie przypisuje każdy punkt danych do najbliższego centroidu, a potem aktualizuje pozycje centroidów jako średnie z przypisanych im punktów. Proces ten powtarza się aż do ustabilizowania się klastrow. Celem metody jest minimalizacja wewnątrzklustrowej sumy kwadratów odległości (ang. Within-Cluster Sum of Squares – WSS). K-means jest szczególnie użyteczna do segmentacji danych i znajdowania struktur w dużych zbiorach danych. Algorytm K-Means został zaimplementowany w pracy pod tytułem "A K-Means Clustering Algorithm", autorstwa J. A. Hartigan i M. A. Wong (8).


Wzór metody K-Means:

$$WSS = \sum_{j=1}^K \sum_{i \in C_j} \|x_i - \mu_i\|^2$$

gdzie:

- K – liczba klastrow,
- C_j – zbiór punktów należących do klastra j ,

- x_i – wektor cech i-tego obiektu,
- μ_j – centroid klastra j ,
- $\|x_i - \mu_j\|^2$ – kwadrat euklidesowej odległości pomiędzy punktem x_i a środkiem klastra μ_j



Rysunek 4: Przykładowy wykres klasyfikacji diamentów metodą K-Means

13. Metoda Warda


Metoda Warda jest jedną z technik hierarchicznej analizy skupień. Działa od dołu (agglomerative), zaczynając od traktowania każdego obiektu jako osobnego klastra, a następnie łącząc je parami, aż powstanie jeden duży klaster zawierający wszystkie dane. Przy każdym kroku łączone są te dwa klastry, których połączenie powoduje najmniejszy przyrost całkowitej wariancji wewnątrzklustrowej. Dzięki temu powstają zwarte i dobrze oddzielone grupy. Metoda ta jest szczególnie przydatna, gdy chcemy wizualnie przeanalizować strukturę danych (np. na dendrogramie) i uzyskać klastery o podobnej liczności i kształcie. Po raz pierwszy została zaproponowana przez Joe H. Ward'a Jr. w pracy pod tytułem "Hierarchical Grouping to Optimize an Objective Function" (7).

Wzór metody Warda:

$$\Delta ESS = \frac{n_1 \cdot n_2}{n_1 + n_2} \cdot \|\mu_1 - \mu_2\|^2$$

gdzie:


- n_1, n_2 - liczba punktów w dwóch klastrach, które chcemy połączyć
- μ_1, μ_2 - centroidy tych dwóch klastrów
- $\|\mu_1 - \mu_2\|^2$ - kwadrat odległości euklidesowej między środkami klastrów
- ΔESS - przyrost wewnątrzklustrowej sumy kwadratów odchyłeń po połączeniu klastrów



Rysunek 5: Przykładowy wykres klasyfikacji diamentów dla metody Warda

14. Metoda łokcia

Metoda łokcia (ang. Elbow Method) służy do ustalenia optymalnej liczby klastrów w algorytmach klasteryzacji, takich jak k-means. Polega na obliczaniu całkowitej sumy kwadratów odległości punktów od centrów swoich klastrów (WSS) dla różnych wartości k . Następnie wyniki te przedstawia się na wykresie. W punkcie, w którym dalsze zwiększanie liczby klastrów przestaje znacząco zmniejszać wartość WSS (tworząc tzw. "łokiec" na wykresie), uznaje się, że znajduje się optymalna liczba klastrów. Metoda ta pozwala uniknąć nadmiernego dzielenia danych i pomaga dobrać taką liczbę grup, która najlepiej odwzorowuje ich strukturę. Została wspomniana w artykule pod tytułem "Klastrowanie metodą K-Means: techniki znajdowania optymalnych klastrów" (6).



Rysunek 6: Wykres metody łokcia dla metody K-Means


Dla metody Warda nie da się zrobić wykresu łokcia, bo nie liczy takiej metryki jak KMeans, z tego powodu zamiast tego użyliśmy silhouette score.

15. Metoda Silhouette Score


Silhouette score – to metoda określająca jakość klastrów wygenerowanych, przez algorytmy klasteryzacji takie jak K-means, dla danej liczby klastrów. Polega na obliczeniu średnich odległości punktu od innych punktów z jego klastra (a) oraz punktów z najbliższego klastra, do którego nie należy (b). Następnie zgodnie ze wzorem:

$$\frac{b-a}{\max(a;b)}$$

obliczany zostaje wynik dla danego punktu. Gdy wszystkie punkty mają swój wynik, obliczana zostaje średnia tych wyników i na jej podstawie ocenia się jakość klastrowania. Wyniki są tym lepsze im bliższe są wartości 1, gdzie wartości powyżej 0.5 uznaje się za dobre, a powyżej 0,25 za akceptowalne. Metoda ta została użyta w pracy pod tytułem *“Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis”*, autorstwa Peter’a J. Rousseeuw (5).



Rysunek 7: Wykres metody Silhouette Score dla metody K-Means



Rysunek 8: Wykres metody Silhouette Score dla metody Warda


16. Wybór ilości klastrow

Liczbę klastrow ustalono na 3 na podstawie metody łokcia oraz analizy silhouette score. Choć najwyższy silhouette wystąpił dla 2 klastrow, taki podział był zbyt ogólny i nie dawał wystarczającego zróżnicowania między grupami. Wybór 3 klastrow stanowi kompromis między dobrą jakością podziału a jego użytecznością interpretacyjną.


17. Rezultaty

Każdy z wykresów przedstawia punkty reprezentujące diamenty w dwóch wybranych cechach, ugrupowane w klastry powstałe z metody K-Means lub Warda. Punkty należące do poszczególnych klastrów w obu metodach zostały jednakowo pokolorowane.


18. Wykresy K-Means




Rysunek 9. Powyższy wykres przedstawia wzrost cen diamentów wraz ze wzrostem karatu (masy). Można także zaobserwować pionowe zagęszczenia dla wartości karatu 1, 1.5, 2, 3, co obrazuje obróbkę diamentów tak, aby miały równą wartość karatu. Widać także nagły, nieproporcjonalny skok ceny po progu 1 karata, mimo że wciąż znajdują się one w klastrze "średnich" diamentów. Sugeruje to, że nawet diamenty o nienajlepszych cechach mogą zostać sprzedane po wyższej cenie, jeśli tylko osiągną masę 1 karata.



Rysunek 10. Za idealną głębokość procentową diamentu uznaje się wartości 58%-62%, co oznacza, że jego wysokość jest nieco dłuższa niż połowa średnicy. Na powyższym wykresie można zaobserwować punkty coraz bardziej zbiegające ku tym wartościom wraz ze wzrostem ich cen.



Rysunek 11. Punkty tworzą wyraźnie zakrzywiony układ – łukowatą strukturę, która wynika z nieliniowej zależności pomiędzy długością diamentu a jego masą. Podział odzwierciedla ogólny trend wzrostu, ale ze względu na łukowaty charakter danych, granice między klastrami nie są idealnie prostopadłe do osi x ani carat.




Rysunek 12: Porównanie wpływu cech cut, clarity i color na cenę.


Na podstawie analizy wyników klasteryzacji K-Means można stwierdzić, że największy wpływ na cenę diamentu spośród zmiennych jakościowych ma cecha cut. Diamenty o najwyższej jakości szlif (wartość 1) są wyraźnie skupione w klastrze odpowiadającym najwyższym cenom (kolor zielony), natomiast diamenty o najniższym szlifie praktycznie w ogóle się tam nie pojawiają.

Z kolei w przypadku cech color i clarity widać, że diamenty o wysokiej cenie (klastery zielony) skupiają się głównie w średnich klasach tych cech, a nie na ich najwyższych poziomach. Oznacza to, że choć kolor i czystość mają pewien wpływ na wartość diamentu, to nie jest on tak istotny i jednoznaczny jak w przypadku jakości szlif.

19. Wykresy Warda



Rysunek 13. Granice pomiędzy klastrami są bardzo regularne i zgodne z rosnącym trendem, co wskazuje na to, że metoda Ward dobrze odwzorowuje naturalną strukturę danych w tej przestrzeni.




Rysunek 14.


20. Klasyfikacja bez nadzoru

Wykresy klastrów sporządzonych metodami K-Means i Warda porównano z wykresami, na których punkty przydzielono do trzech grup cenowych na podstawie trzech kwantyli rozkładu zmiennej *price*. Grupy zostały pokolorowane zgodnie z kolorami zbliżonych im klastrów.


- Grupa cen niskich (oznaczona kolorem **czzerwonym**)
- Grupa cen średnich (oznaczona kolorem **niebieskim**)
- Grupa cen wysokich (oznaczona kolorem **zielonym**)



Rysunek 15: Porównanie klastrow K-Means i Warda w zmiennych depth/table z grupami cenowymi. Punkty odbiegające od centrum są prawie zawsze czerwone lub niebieskie, co oznacza, że zielone (najdroższe) są najbliższe idealnych wartości depth i table (kolejno 60%, 55%)



Rysunek 16: Na wykresie K-Means widać lepszą zgodność klastrów z grupami cenowymi, ale metoda Warda również dała zbliżone rezultaty. Sugeruje to, że diamenty podzielone według wszystkich cech rzeczywiście odwzorowują w pewnym stopniu ich podział cenowy.



Rysunek 17: Granice między klastrami są ostrzejsze na wykresach K-Means, a bardziej rozproszone na wykresach Warda.

Analiza wizualna wykresów pozwala zaobserwować, na ile zgodne są klastry wygenerowane przez algorytmy z rzeczywistym podziałem cenowym. W przypadku metody Warda klastry wykazują większe rozproszenie punktów na granicach klastrów niż w metodzie K-Means.

W celu lepszej oceny zgodności klastrów z grupami cenowymi obliczono dla każdej metody pokrycie, czyli procent punktów, które przynależą do odpowiadających sobie klastrów i grup cenowych.

Pokrycie dla metody K-Means wyniosło **69.86%**

Pokrycie dla metody Warda wyniosło **37.78%**

21. Podsumowanie

22. Wnioski z analizy danych

Przeprowadzona analiza wykazała, że cena diamentów jest ściśle powiązana z ich cechami fizycznymi, przede wszystkim z ich masą (karat), czystością oraz jakością szlifu. Zaobserwowano, że wzrost wartości tych atrybutów zwykle wiąże

się z wyższą ceną, choć zależność ta nie zawsze jest liniowa. W szczególności masa diamentu wykazuje silną korelację z ceną, co było widoczne na wykresach pokazujących skokowe zmiany cen przy osiągnięciu „okrągłych” wartości karatu (np. 1, 1.5, 2). Z drugiej strony cechy takie jak głębokość (depth) i tafla (table) okazały się ważne, ale raczej jako destymulanty – odstępstwa od wartości uznawanych za idealne mogą znacząco obniżać wartość rynkową diamentu.

23. Ocena metod klasteryzacji

Zastosowanie dwóch metod, metody K-Means i metody Warda, pozwoliło na pogłębioną ocenę struktury danych.

K-Means lepiej odwzorowywała naturalne klastry w przestrzeni cech diamentów i charakteryzowała się wyraźnymi granicami między grupami. Wskaźnik pokrycia cenowego (blisko 70%) sugeruje, że algorytm ten dobrze odzwierciedlał różnice wartości rynkowej pomiędzy diamentami.

Metoda Warda, mimo mniejszego pokrycia (ok. 38%), pozwoliła uzyskać klastry o zbliżonej liczności.

24. Znaczenie wyników

Wyniki analizy potwierdzają praktyczne zastosowanie klasteryzacji jako narzędzia wspomagającego wycenę diamentów i wykrywanie anomalii. Dzięki metodom grupowania możliwe było wskazanie przypadków, w których cena diamentu nie była spójna z jego właściwościami.

25. Rekomendacje i możliwości dalszych badań

W przyszłości warto byłoby rozszerzyć analizę o dodatkowe cechy, a także uwzględnić dane z rynku – np. pochodzenie kamienia czy certyfikaty. Ciekawym kierunkiem byłaby również implementacja algorytmów opartych na uczeniu głębokim (np. autoenkoderów) lub testowanie algorytmów klasteryzacji gęstościowej, takich jak DBSCAN.

26. Realizacja celu

- Klastry utworzone na podstawie cech fizycznych są zbliżone do grup cenowych, zatem istnieje znaczący związek między ceną diamentu a jego rzeczywistymi właściwościami.
- W analizie zauważono, że dwie cechy, karat i szlif, mają największy wpływ na wartość diamentów. W następnej kolejności na cenę wpływają kolejno czystość i kolor, a najmniejszy wpływ mają szerokość tafla oraz wysokość.

- Jeśli diament przekracza masę 1 karatu, może zostać sprzedany po wyższej cenie niż sugerowałyby jego inne cechy. Oznacza to, że próg 1 karatu jest poniekąd wymówką pozwalającą sprzedać diament o gorszych cechach po podobnej cenie, co diamenty o najlepszych cechach. Zatem karat wpływa na cenę bardziej niż można by oczekiwać na podstawie samej zależności ceny od masy, jest używany jako pewna oznaka prestiżu.
- Spośród cech dyskretnych (szlif, kolor i czystość), szlif jest najważniejszy, jako że najwięcej drogich diamentów znalazło się w najlepszej kategorii szlif. Kolor wpływa na cenę najmniej, co widać z jednolitego rozkładu drogich diamentów na kategorie koloru. Natomiast czystość ma średnią ważność - drogie diamenty są rozłożone dość równomiernie w jej kategoriach, z wyjątkiem dwóch najgorszych kategorii.

27. Porównanie z wynikiem z literatury

Nasze wnioski pokrywają się w większości z danymi i wnioskami przedstawionymi przez 301 carats (9). Tak jak my, wskazują oni na największy wpływ karatu na cenę diamentu. Jako kolejną cechę wskazują szlif, z różnicą cen, między najlepszym i najgorszym szlifem na poziomie 60%, co również zgadza się z naszymi obserwacjami. Trzecia cecha z różnicą na poziomie 54% jest czystość.

28. Bibliografia

1. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*.
2. Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.).
3. Gemological Institute of America. *The Four Cs of Diamond Quality*. Pobrano z: <https://www.gia.edu/diamond-quality-factor>
4. Read, P. G. (2005). *Gemmology* (3rd ed.).
5. Peter J. Rousseeuw. *Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis*
<https://www.sciencedirect.com/science/article/pii/0377042787901257?via%3Dihub>
6. Klastrowanie metodą K-Means: techniki znajdowania optymalnych klastrów
<https://ichi.pro/pl/klastrowanie-metoda-k-means-techniki-znajdowania-optymalnych-klastrow-139544899986683>
7. Ward, J. H. (1963). Hierarchical Grouping to Optimize an Objective Function. *Journal of the American Statistical Association*, 58(301), 236–244.
<https://doi.org/10.1080/01621459.1963.10500845>

8. J. A. Hartigan i M. A. Wong. A K-Means Clustering Algorithm
<https://www.jstor.org/stable/2346830?origin=crossref>
9. Serwis 301 Carats <https://301carats.com/blogs/edukacja/od-czego-zalezy-cena-diamentow>